



BDA
Pràctica 2

Predicció de les subvencions NSF que cancel·larà en Trump

Eloi Pagès i Gerard Grau
Desembre 2025

1 Dataset and Business Problem (A.1)

Les subvencions de la National Science Foundation (NSF) són un element indispensable per a molts laboratoris dels Estats Units. Cada any s'aproven al voltant de 12.000 noves subvencions, que permeten finançar centres de recerca arreu del país.

L'abril de 2025, l'administració Trump va decidir cancel·lar una part significativa d'aquestes subvencions, al·legant que afavorien polítiques de diversitat, igualtat, col·lectius minoritaris o, com va anomenar Cruz, "Woke grants".

L'objectiu del nostre projecte és desenvolupar un model matemàtic capaç de predir quines subvencions tenen una probabilitat més elevada de ser cancel·lades en cas que Donald Trump torni a iniciar un nou episodi massiu de cancel·lacions.

1.1 Dataset principal

Aquesta secció té com a objectiu il·lustrar les dades utilitzades. Podeu veure l'Annex 6 per a informació més detallada.

Dataset	Descripció	Format
NSF awards	Conjunt complet de subvencions aprovades per la NSF entre 2013 i 2025	JSON
Cruz list	Llista de subvencions considerades com "woke" per Cruz.	CSV
Legislators historical	Informació de representants i senadors dels EUA per estat i any.	JSON
Flagged words	Conjunt de paraules clau en les que les subvencions no es poden basar segons en Trump	CSV
NSF terminations	Registre de subvencions cancel·lades anticipadament per la NSF en el mandat trump	CSV

Taula 1: Datasets utilitzats en el projecte.

2 Data Lake Architecture & Pipelines (A.2)

Un cop enteses les dades, expliquem com hem construït la pipeline per poder entrenar de manera ràpida els nostres models predictius. Aquest és el diagrama que hem fet:




Figura 1: Pipeline de Dades

2.1 Landing zone

La *landing zone* és la capa més baixa del nostre *data lake* i té com a objectiu emmagatzemar les dades de la manera més fidel possible a la font original. Les dades arriben a la *landing zone* mitjançant scripts de tipus `collect`, encarregats de descarregar informació de diferents orígens i guardar-la dins del *data lake*.

Les dades de Awards les extraïem de la API oficial mitjançant el seu script. Al ser una API del govern triga molt a donar resposta i està limitada a 25 respostes per crida. Donat que volen descarregar més de 150 000 subvencions, aquest script triga aproximadament unes 6 hores en correr. El dataset de flagged words, com no té link de descàrrega, el seu `collect` copia el fitxer del local a la landing zone. La resta de dades les descarreguem directament d'un link de descàrrega a internet mitjançant funcions de python.

2.2 Formatted zone

La *formatted zone* conté les dades ja processades i normalitzades, llestes per ser utilitzades de manera consistent en fases posteriors d'anàlisi o modelatge. Aquesta zona s'alimenta exclusivament de la *landing zone* mitjançant scripts de tipus `formatter`, que llegeixen les dades en brut i hi apliquen una sèrie de transformacions estructurals i semàntiques.

El sistema utilitza configuracions explícites per dataset (`FormatterConfig`) que defineixen mapejaments de columnes, formats de dates i validacions específiques per a cada font de dades. El flux de processament aplica operacions de renomemat de columnes (per exemple, conversió de camelCase a snake_case), parsejat de dates amb formats específics, conversió de tipus numèrics i booleans, i transformacions personalitzades quan és necessari (com la neteja de valors categòrics nuls o el filtratge de paraules invàlides). Un cop processades, les dades es carreguen a MongoDB amb índexs optimitzats sobre els camps clau (`award_id`, `award_number`, etc.) per facilitar l'accés en fases posteriors.

2.3 Exploitation zone

La *exploitation zone* és la capa orientada directament a l'ús analític i predictiu de les dades. A partir de les dades ja consolidades a la *formatted zone*, en aquesta etapa es construeixen *datasets* específics per a l'entrenament de models, l'avaluació de resultats i l'explotació analítica.

3 Airflow DAG

Per fer el disseny del DAG de Airflow tenim 3 opcions diferents. Un flux coníuu de tres fases, collect, format, transform. Un flux amb fases paraleles per cada dataset diferent, collect, format i un transform que es fa al final del DAG amb totes les dades. La tercera opció és fer 5 DAGS diferents, un dag per cada dataset amb collect i format. I fer un sisè DAG que sigui només el transform. Cada una de les opcions té les seves avantatges i al final, en un cas real triaríem la opció que més convé pels interessos del client.

4 Airflow DAG




Figura 2: Opció 1




Figura 3: Opció 2




Figura 4: Opció 3

4.1 Opció 1

Aquesta primera opció no té pràcticament cap avantatge, l'única cosa positiva que podem trobar és que és una pipeline simple i molt fàcil d'entendre on cada etapa consisteix en un bloc de la nostre execució. A sobre, cada dependència té una funció molt clara i general. En quan a eficiència és dolenta.

4.2 Opció 2

Aquesta opció és molt més eficient que la primera, ja que permet l'execució paral·lela de les tasques. El problema que té aquest setup és que no podem correr per separat els 5 datasets. Només podem correr per separat flagged words i els altres 4. Això és perquè el transform fa merges entre els diferents datasets i, per tant, necessita accés als 4.

4.3 Opció 3

Aquesta tercera opció és una manera d'arreglar el segon DAG per tal d'acceptar correr individualment les 5 pipelines. El problema que presenta aquesta és que tenim una pipeline separada d'un sol element que depèn de l'execució de la resta de pipelines. Això ens pots donar problemes de freshness on sense voler podem executar el DAG de transform sense haver acabat els 5 anteriors o encara pitjor, havent acabat 4 dels 5 i no adonar-nos.

4.4 Decisió final

Per fer la decisió final, tenim en compte que totes les dades que estem tractant necessiten la mateixa *freshness* i, per tant, té molt sentit tenir dags executats en el mateix període i tots junts. Això ens porta a triar la segona opció. Tanmateix, si el client volgués refrescar la taula de awards cada setmana i les altres cada dia, s'haurien de separar els DAG. Per aquest exercici i la simplicitat suposem que el client vol totes les dades amb la mateixa frescor.

5 Machine Learning Results (B.3)

Hem abordat el problema com una classificació binària (`is_terminated`) amb un fort desequilibri de classes (1.7% positius), aplicant pesos de classe i utilitzant la mètrica F1-score. S'han fet servir features numèriques i categòriques (veure Annex 6 per detalls), amb una divisió 80/20 train/test.

Hem entrenat baselines i tres models (LR, RF, GBT) amb Spark MLlib i CrossValidation. Els resultats (Taula 3) mostren la superioritat dels models de ML. Una taula més detallada es pot trobar a l'Annex 6.

Taula 2: Resultats al conjunt de Test

Model	Accuracy	F1-Score	AUC-ROC
Baseline (Stratified)	0.9666	0.0000	0.5000
Logistic Regression	0.8838	0.0718	0.7052
Random Forest	0.9294	0.0984	0.7263
Gradient Boosted Trees	0.8812	0.1063	0.7159

El model de **Gradient Boosted Trees (GBT)** ha estat seleccionat pela seva millor F1-score, indicant una millor detecció de cancel·lacions. Finalment, aquest model s'ha etiquetat com a `best_f1` a MLflow i està disponible per a desplegament. Els hiperparàmetres, mètriques i artefactes del model es poden consultar a l'experiment




Figura 5: Corbes ROC




Figura 6: Matrius de confusió dels models entrenats (conjunt de test)

6 ANNEX

6.1 Explicació dades utilitzades

NSF Awards

Aquest dataset conté, en format JSON, el conjunt de subvencions concedides per la *National Science Foundation* entre els anys 2013 i 2025. Per a cada grant s’hi inclou l’identificador oficial, així com informació descriptiva rellevant, com ara el títol, l’abstract, la institució beneficiària, el projecte associat, el nom del *Principal Investigator* (PI) i la quantitat econòmica concedida, entre d’altres.

Cruz List

Aquest dataset, en format CSV, correspon a la llista publicada pel senador Ted Cruz de les subvencions de la NSF que ell va considerar ideològicament sensibles. A més de l’identificador de la subvenció, el conjunt de dades inclou informació addicional com el motiu pel qual cada grant va ser classificada com a “woke” i altres observacions específiques.

Legislators Historical

Atès que el context polític pot tenir un paper rellevant en les decisions de cancel·lació, aquest dataset en format JSON proporciona informació històrica sobre els representants i senadors dels Estats Units, incloent-hi el partit polític i el període temporal durant el qual van exercir el càrrec.

NSF Terminations

Aquest dataset, en format CSV, conté els identificadors de les subvencions de la NSF que van ser cancel·lades per l’administració Trump a l’abril de 2025. Cal destacar que aquestes cancel·lacions no s’han publicat oficialment de manera centralitzada, sinó que han estat estimades a partir de diverses fonts i anàlisis independents, que han donat lloc a aquest conjunt de dades agregat.

Flagged Words

Finalment, aquest dataset consisteix en una llista de paraules clau associades a conceptes de diversitat, gènere i minories, utilitzada per extreure característiques textuais dels títols i abstracts de les subvencions. La seva incorporació resulta clau perquè el model pugui captar patrons semàntics relacionats amb els criteris ideològics que podrien influir en les decisions de cancel·lació.

6.2 Features usades en el modelatge

- **Features numèriques:**
 - `estimated_total_amt`: quantitat total estimada de la subvenció
 - `funds_obligated_amt`: fons compromesos

- `flagged_word_count_abstract`: nombre d'ocurrències de paraules clau sensibles a l'abstract
- `flagged_word_unique_abstract`: nombre de paraules clau úniques a l'abstract
- `flagged_word_ratio_abstract`: proporció de paraules clau respecte al total de paraules a l'abstract
- `flagged_word_count_title`: nombre d'ocurrències de paraules clau al títol
- `flagged_word_diversity_score`: diversitat de paraules clau utilitzades
- **Features categòriques:**
 - `perfstatecode`: codi de l'estat on es realitza la recerca
 - `representant`: partit polític del representant de l'estat
 - `senator`: partit polític del senador de l'estat
- **Features booleanes:**
 - `has_flagged_words`: presència de paraules clau sensibles al títol o abstract
 - `in_cruz_list`: si la subvenció apareix a la llista de Cruz (indicador predictiu important)
- **Variable objectiu:** `is_terminated` (1 = cancel·lada, 0 = activa)

6.3 Comparació de rendiment dels models

Taula 3: Comparació de rendiment dels models

Model	Accuracy	F1-Score	AUC-ROC
<i>Validation Set</i>			
Baseline (Majority)	0.9856	0.0000	0.5000
Baseline (Random)	0.4928	0.0306	0.5000
Baseline (Stratified)	0.9688	0.0488	0.5000
Logistic Regression	0.8952	0.0576	0.7024
Random Forest	0.9344	0.0682	0.6730
Gradient Boosted Trees	0.8776	0.0727	0.6548
<i>Test Set</i>			
Baseline (Majority)	0.9833	0.0000	0.5000
Baseline (Random)	0.4888	0.0293	0.5000
Baseline (Stratified)	0.9666	0.0000	0.5000
Logistic Regression	0.8838	0.0718	0.7052
Random Forest	0.9294	0.0984	0.7263
Gradient Boosted Trees	0.8812	0.1063	0.7159